WEB SCRAPING CON PYTHON

Ejercicios de Web Scraping con Python

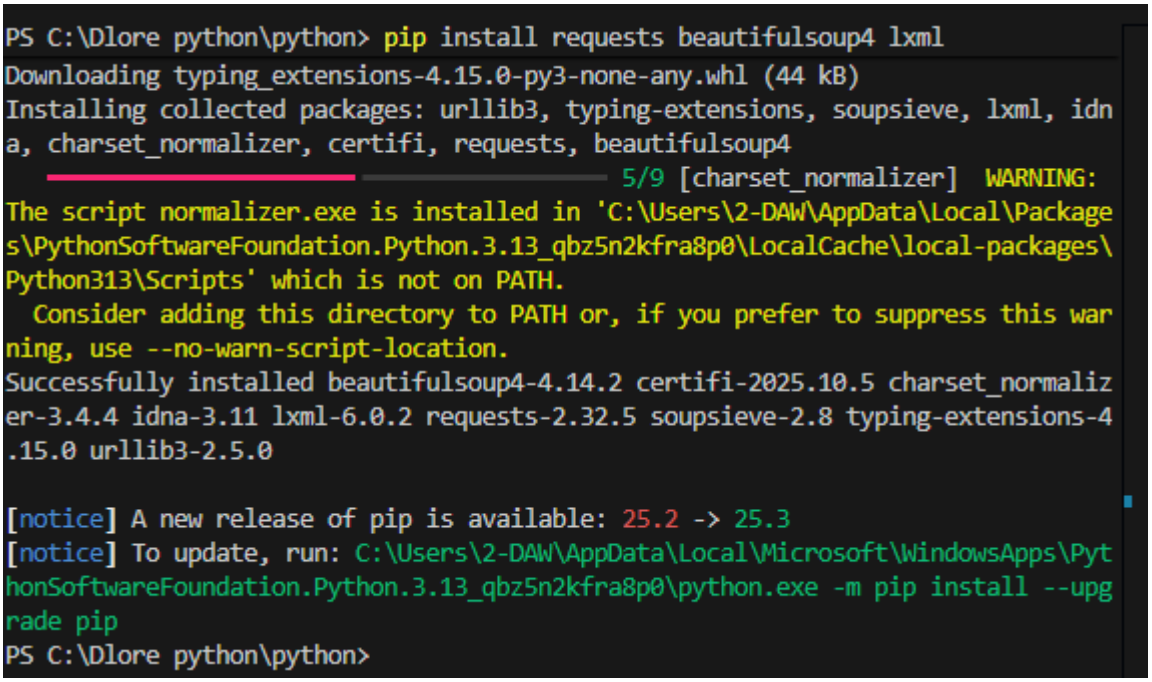
🔧 Requisitos previos

- Python instalado.

- Librerías: `requests`, `beautifulsoup4`, `lxml` o `html.parser`.

Instalación (si no están):

```
pip install requests beautifulsoup4 lxml
```



📘 Ejercicio 1: Extraer titulares de una web de noticias

Objetivo: Obtener los títulos de las últimas noticias de https://elpais.com o similar.

Instrucciones:

1. Usar `requests` para obtener el HTML.

2. Parsear con BeautifulSoup.

3. Imprimir los titulares (por ejemplo, etiquetas `<h2>`).

Código base:

```
import requests
from bs4 import BeautifulSoup

url = "https://elpais.com/"
response = requests.get(url)
soup = BeautifulSoup(response.text, 'html.parser')

titulos = soup.find_all('h2')

for i, titulo in enumerate(titulos[:10]):
    print(f"{i+1}. {titulo.get_text(strip=True)}")
```

ejemplo 1 con el pais

```python
import requests
from bs4 import BeautifulSoup

url = "https://elpais.com/"
response = requests.get(url)
soup = BeautifulSoup(response.text, 'html.parser')

titulos = soup.find_all('h2')

for i, titulo in enumerate(titulos[:10]):
    print(f"{i+1}. {titulo.get_text(strip=True)}")
```

```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscraping.py"
1. 72 horas encerrado en la Casa de las Brujas o cómo se gestó la dimisión de Mazón: “Me quiero ir”
2. Feijóo se prepara para una negociación a cara de perro en Valencia y un alto riesgo de ir a elecciones
3. Los familiares de las víctimas de la dana, en el Congreso: “No los mató el clima, los mató la mala gestión”
4. Cronología de una caída
5. El reguero de incógnitas que deja la declaración de Maribel Vilaplana
6. Juicio al fiscal general
7. Arde Mas Marroch, el espacio de eventos de los Roca en Girona: “Son momentos de desolación”
8. Opinión
9. Actualidad
10. Qué significa el “6-7” o “six seven” que dicen tus hijos, si es que significa algo
PS C:\Dlore python\python>
```

ejemplo 2 con el mundo

```python
import requests
from bs4 import BeautifulSoup

url = "https://www.elmundo.es/"
response = requests.get(url)
soup = BeautifulSoup(response.text, 'html.parser')

titulos = soup.find_all('h2')

for i, titulo in enumerate(titulos[:10]):
    print(f"{i+1}. {titulo.get_text(strip=True)}")
```

```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscraping.py"
1. La UCO entrega nuevos 'whatsapps' de Koldo presionando al ministro Torres para pagar a Aldama
2. Tienes 6 intentos y 1 sola palabra
3. Sabes más palabras de las que crees
4. Encuentra las palabras ocultas
5. Tu reto diario en nivel fácil
6. No todos lo terminan... ¿Tú podrás?
7. La UCO entrega 'whatsapps' de Koldo presionando al ministro Torres para pagar a Aldama: 'Si lo consigues, me dejo violar por ti''
8. Demoledor arranque del juicio contra García Ortiz: fiscales reflejan la insólita actuación con el novio de Ayuso
9. Torres, el ministro "ejemplar" para Sánchez: "Me voy a cagar en todos los santos con la responsable económica"
10. Nueve amenazas para Ábalos en su primer juicio con una larga condena de cárcel sobrevolando
```

📑 Ejercicio 2: Obtener precios de productos (simulación de ecommerce)

Objetivo: Extraer nombre y precio de productos desde una tienda como https://books.toscrape.com

Instrucciones:

1. Scrapea título del libro, precio y disponibilidad.

2. Muestra al menos 5 productos.

Código base:

```
import requests
from bs4 import BeautifulSoup

url = "https://books.toscrape.com/"
res = requests.get(url)
soup = BeautifulSoup(res.text, 'html.parser')

libros = soup.select("article.product_pod")

for libro in libros[:5]:
      titulo = libro.h3.a['title']
      precio = libro.select_one(".price_color").text
      print(f"{titulo} - {precio}")
```

```python
import requests
from bs4 import BeautifulSoup

url = "https://books.toscrape.com/"
res = requests.get(url)
soup = BeautifulSoup(res.text, 'html.parser')

libros = soup.select("article.product_pod")

for libro in libros[:5]:
    titulo = libro.h3.a['title']
    precio = libro.select_one(".price_color").text
    print(f"{titulo} - {precio}")
```

```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscraping2.py"
A Light in the Attic - Â£51.77
Tipping the Velvet - Â£53.74
Soumission - Â£50.10
Sharp Objects - Â£47.82
Sapiens: A Brief History of Humankind - Â£54.23
PS C:\Dlore python\python>
```

📅 Ejercicio 3: Recoger eventos de una página (tipo agenda cultural)

Objetivo: Acceder a una web como https://www.malaga.es/agenda/ y obtener los eventos del día.

Instrucciones:

- Scrapea título, fecha y descripción breve.

- Permite guardar los resultados en un `.txt`.

- para realizar este ejercicio hay que usar selenium, debido a que la web de la agenda cultural está realizada con javascript y eso impide que se pueda usar los ejercicios anteriores.
- pip install selenium, también hay que importar webdriver: pip install selenium webdriver-manager.

Solución

```
import os
import time


from selenium import webdriver
from selenium.webdriver.chrome.options import Options
from selenium.webdriver.chrome.service import Service
from webdriver_manager.chrome import ChromeDriverManager


options = Options()
options.add_argument("--headless")
options.add_argument("--window-size=1920,1080")


driver =
webdriver.Chrome(service=Service(ChromeDriverManager().install())
, options=options)
driver.get("https://www.malaga.es/agenda/")
time.sleep(5)


html = driver.page_source
```

```
ruta = os.path.join(os.getcwd(), "agenda_page.html")

print(f"Guardando HTML en: {ruta}")



try:

      with open(ruta, "w", encoding="utf-8") as f:

      f.write(html)

      print("✅ HTML guardado correctamente.")

except Exception as e:

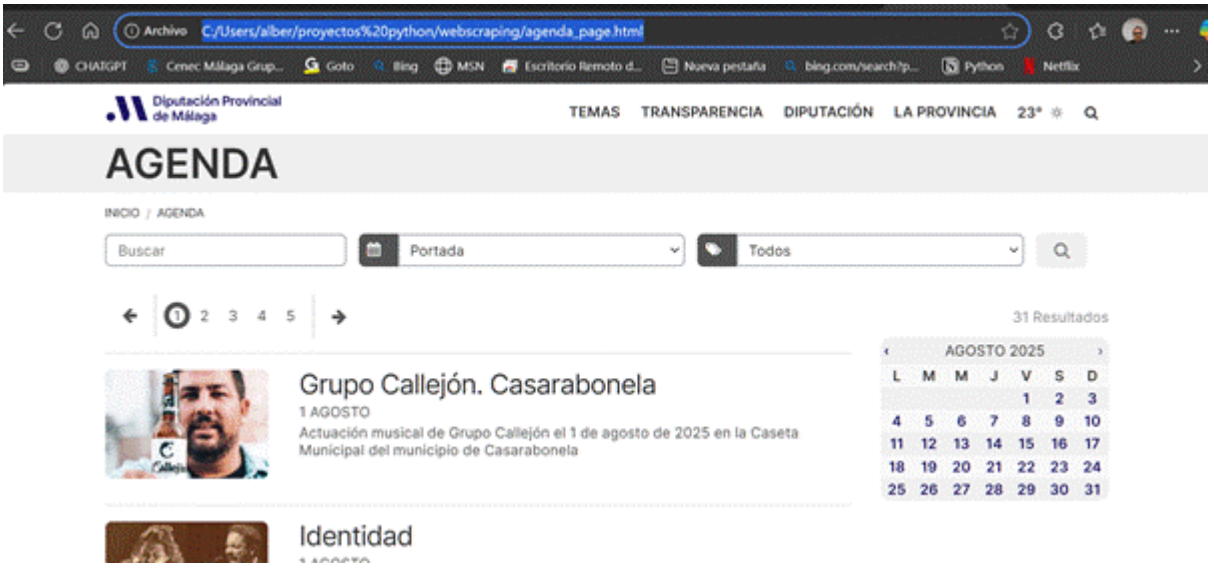
      print("❌ Error al guardar el archivo:", e)

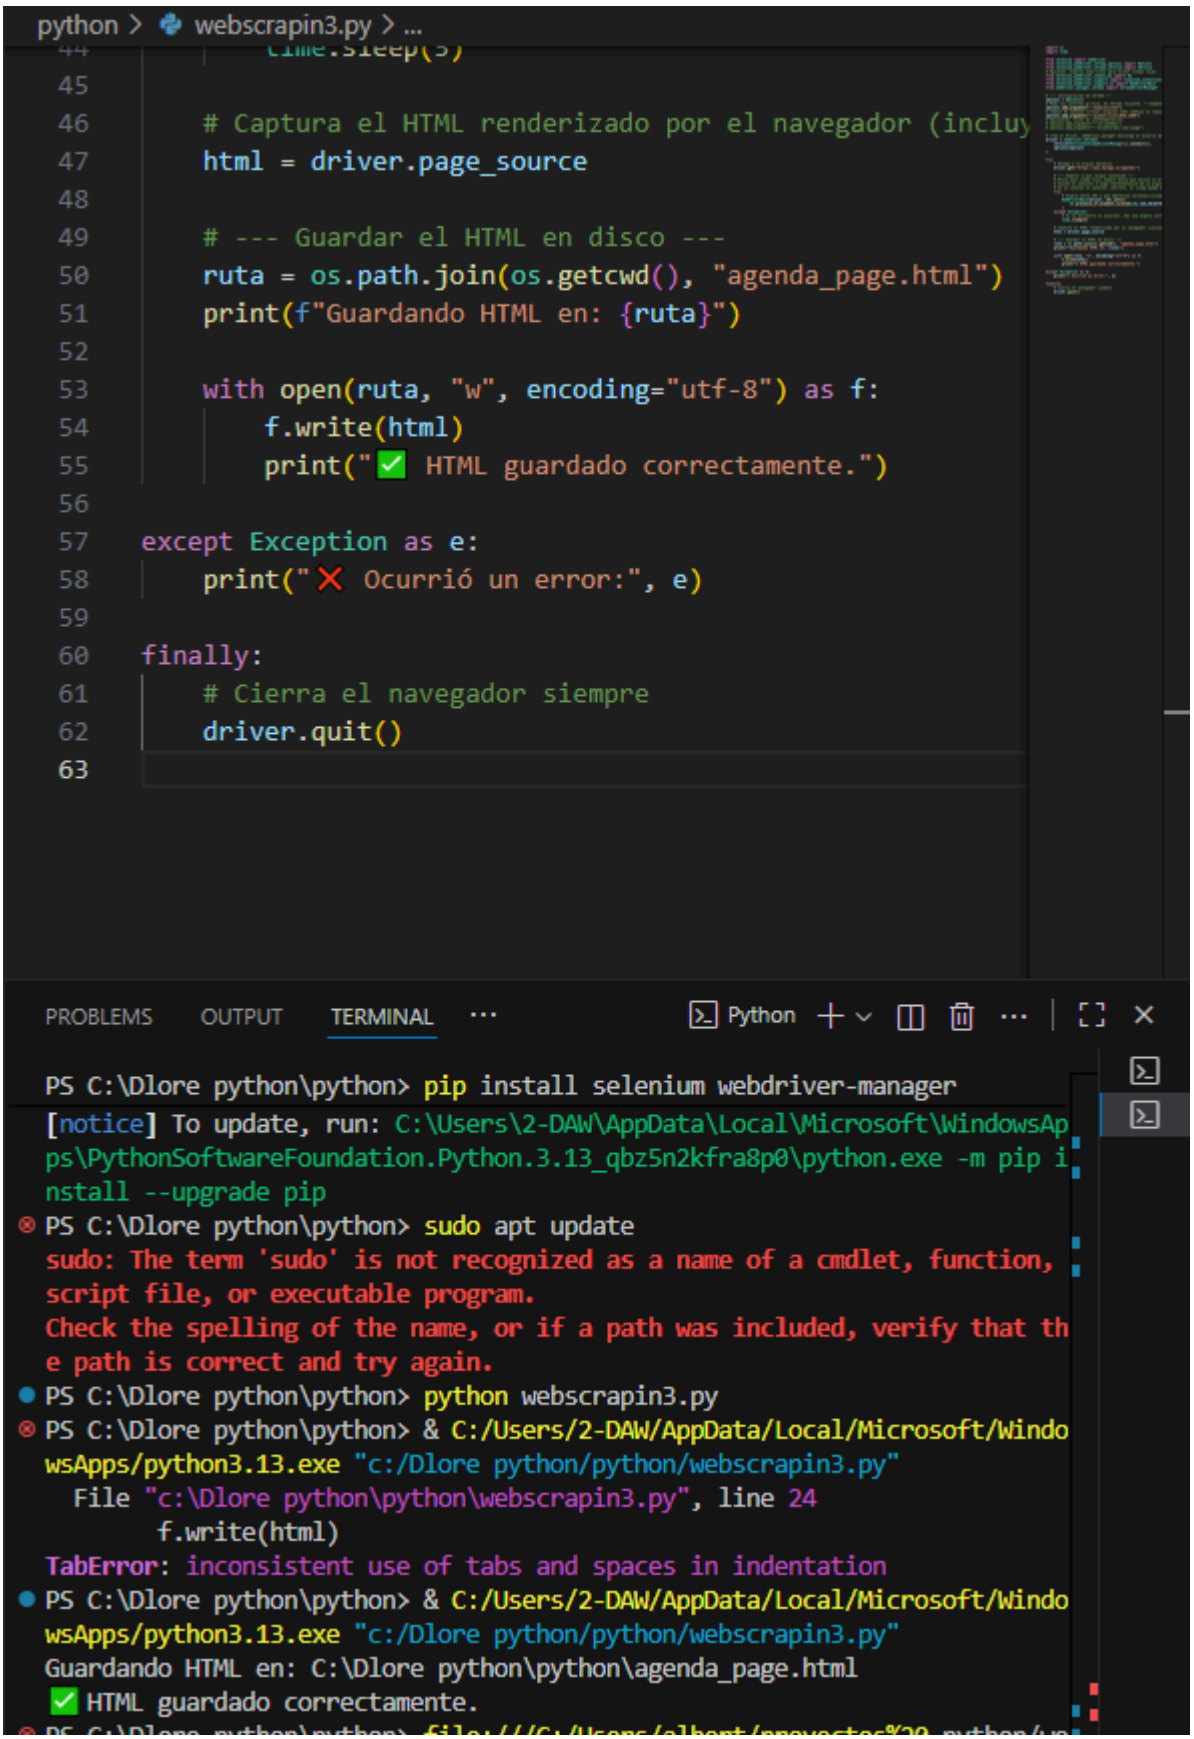


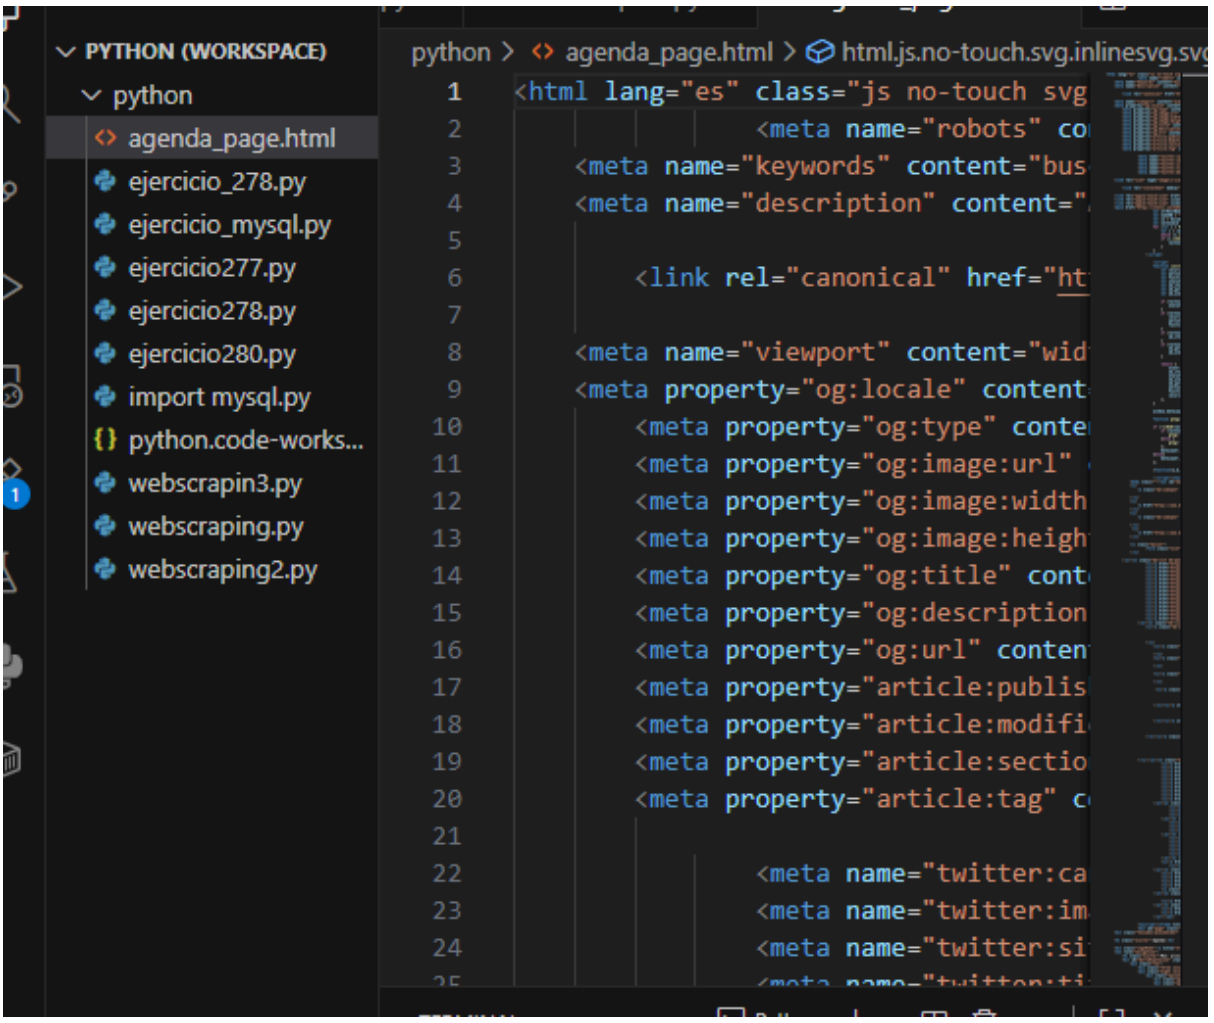
driver.quit()
```

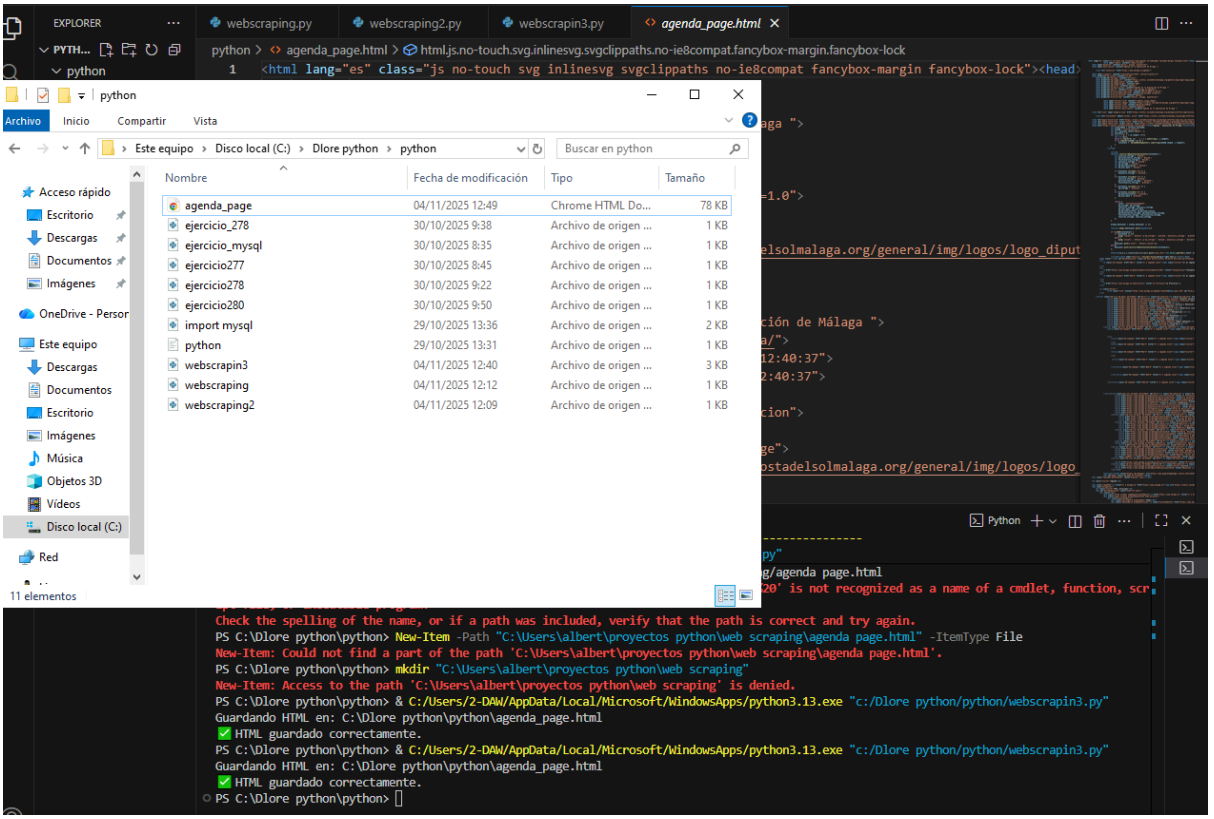
Genera un fichero en esta ruta

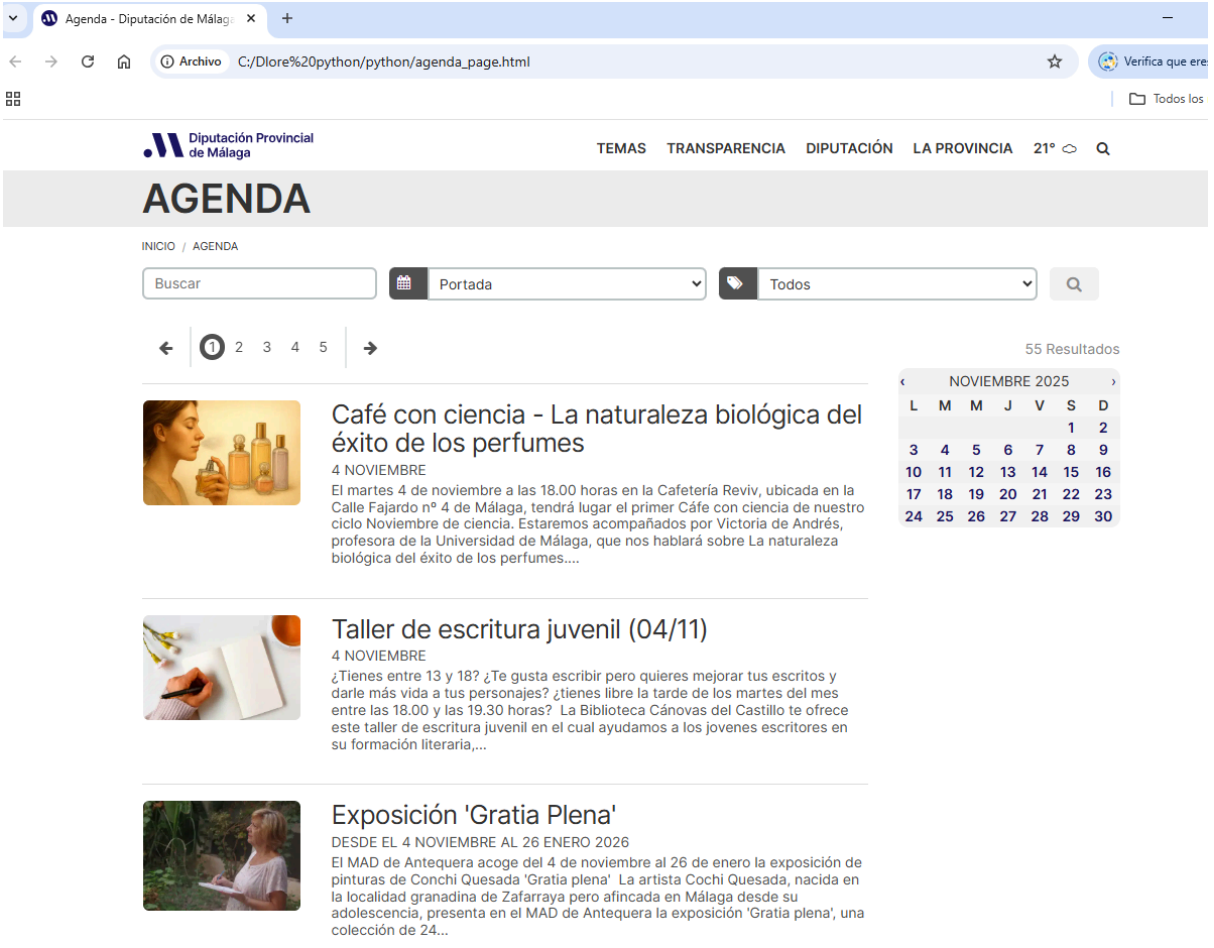
file:///C:/Users/albert/proyectos%20 python/web scraping/agenda page.html




python > webscrapin3.py > ...
time.sleep(5)
Captura el HTML renderizado por el navegador (incluy
html = driver.page_source
--- Guardar el HTML en disco ---
ruta = os.path.join(os.getcwd(), "agenda_page.html")
print(f"Guardando HTML en: {ruta}")
with open(ruta, "w", encoding="utf-8") as f:
f.write(html)
print("✅ HTML guardado correctamente.")
except Exception as e:
print("❌ Ocurrió un error:", e)
finally:
Cierra el navegador siempre
driver.quit()
PROBLEMS
OUTPUT
TERMINAL
Python
PS C:\Dlore python\python> pip install selenium webdriver-manager
[notice] To update, run: C:\Users\2-DAW\AppData\Local\Microsoft\WindowsApps\PythonSoftwareFoundation.Python.3.13_qbz5n2kfra8p0\python.exe -m pip install --upgrade pip
PS C:\Dlore python\python> sudo apt update
sudo: The term 'sudo' is not recognized as a name of a cmdlet, function, script file, or executable program.
Check the spelling of the name, or if a path was included, verify that the path is correct and try again.
PS C:\Dlore python\python> python webscrapin3.py
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscrapin3.py"
File "c:\Dlore python\python\webscrapin3.py", line 24
f.write(html)
TabError: inconsistent use of tabs and spaces in indentation
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscrapin3.py"
Guardando HTML en: C:\Dlore python\python\agenda_page.html
✅ HTML guardado correctamente.


PYTHON (WORKSPACE)
python
agenda_page.html
ejercicio_278.py
ejercicio_mysql.py
ejercicio277.py
ejercicio278.py
ejercicio280.py
import mysql.py
python.code-works...
webscrapin3.py
webscraping.py
webscraping2.py
python > agenda_page.html > html.js.no-touch.svg.inlinesvg.svg
<html lang="es" class="js no-touch svg
<meta name="robots" co
<meta name="keywords" content="bus
<meta name="description" content="
<link rel="canonical" href="ht
<meta name="viewport" content="wid
<meta property="og:locale" content
<meta property="og:type" conte
<meta property="og:image:url"
<meta property="og:image:width
<meta property="og:image:heigh
<meta property="og:title" cont
<meta property="og:description
<meta property="og:url" conten
<meta property="article:publis
<meta property="article:modifi
<meta property="article:sectio
<meta property="article:tag" c
<meta name="twitter:ca
<meta name="twitter:im
<meta name="twitter:si


webscraping.py
webscraping2.py
webscrapin3.py
agenda_page.html
python > agenda_page.html > html.js.no-touch.svg.inlinesvg.svgclippaths.no-ie8compat.fancybox-margin.fancybox-lock
1 <html lang="es" class="js no-touch svg inlinesvg svgclippaths no-ie8compat fancybox-margin fancybox-lock"><head>
Archivo Inicio Compartir Vista
Este equipo > Disco local (C:) > Dlore python > python
Buscar en python
Nombre Fecha de modificación Tipo Tamaño
agenda_page 04/11/2025 12:49 Chrome HTML Do... 78 KB
ejercicio_278 30/10/2025 9:38 Archivo de origen ... 1 KB
ejercicio_mysql 30/10/2025 8:35 Archivo de origen ... 1 KB
ejercicio277 30/10/2025 8:45 Archivo de origen ... 1 KB
ejercicio278 30/10/2025 9:22 Archivo de origen ... 1 KB
ejercicio280 30/10/2025 9:50 Archivo de origen ... 1 KB
import mysql 29/10/2025 13:36 Archivo de origen ... 2 KB
python 29/10/2025 13:31 Archivo de origen ... 1 KB
webscrapin3 04/11/2025 12:40 Archivo de origen ... 3 KB
webscraping 04/11/2025 12:12 Archivo de origen ... 1 KB
webscraping2 04/11/2025 12:09 Archivo de origen ... 1 KB
11 elementos
Check the spelling of the name, or if a path was included, verify that the path is correct and try again.
PS C:\Dlore python\python> New-Item -Path "C:\Users\albert\proyectos python\web scraping\agenda page.html" -ItemType File
New-Item: Could not find a part of the path 'C:\Users\albert\proyectos python\web scraping\agenda page.html'.
PS C:\Dlore python\python> mkdir "C:\Users\albert\proyectos python\web scraping"
New-Item: Access to the path 'C:\Users\albert\proyectos python\web scraping' is denied.
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscrapin3.py"
Guardando HTML en: C:\Dlore python\python\agenda_page.html
HTML guardado correctamente.
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/webscrapin3.py"
Guardando HTML en: C:\Dlore python\python\agenda_page.html
HTML guardado correctamente.
PS C:\Dlore python\python>


Agenda - Diputación de Málaga
Archivo C:/Dlore%20python/python/agenda_page.html
Diputación Provincial de Málaga
TEMAS TRANSPARENCIA DIPUTACIÓN LA PROVINCIA 21°
AGENDA
INICIO / AGENDA
Buscar
Portada
Todos
1 2 3 4 5
55 Resultados
Café con ciencia - La naturaleza biológica del éxito de los perfumes
4 NOVIEMBRE
El martes 4 de noviembre a las 18.00 horas en la Cafetería Reviv, ubicada en la Calle Fajardo nº 4 de Málaga, tendrá lugar el primer Cáfe con ciencia de nuestro ciclo Noviembre de ciencia. Estaremos acompañados por Victoria de Andrés, profesora de la Universidad de Málaga, que nos hablará sobre La naturaleza biológica del éxito de los perfumes....
Taller de escritura juvenil (04/11)
4 NOVIEMBRE
¿Tienes entre 13 y 18? ¿Te gusta escribir pero quieres mejorar tus escritos y darle más vida a tus personajes? ¿tienes libre la tarde de los martes del mes entre las 18.00 y las 19.30 horas? La Biblioteca Cánovas del Castillo te ofrece este taller de escritura juvenil en el cual ayudamos a los jovenes escritores en su formación literaria,...
Exposición 'Gratia Plena'
DESDE EL 4 NOVIEMBRE AL 26 ENERO 2026
El MAD de Antequera acoge del 4 de noviembre al 26 de enero la exposición de pinturas de Conchi Quesada 'Gratia plena' La artista Cochi Quesada, nacida en la localidad granadina de Zafarraya pero afincada en Málaga desde su adolescencia, presenta en el MAD de Antequera la exposición 'Gratia plena', una colección de 24...
NOVIEMBRE 2025
L M M J V S D
1 2
3 4 5 6 7 8 9
10 11 12 13 14 15 16
17 18 19 20 21 22 23
24 25 26 27 28 29 30

📊 Ejercicio 4: Guardar resultados en CSV

Modifica el **Ejercicio 2** para guardar los resultados en un archivo `.csv`.

Pista: Usa la librería `csv` de Python.

Solución:

```
import csv



import requests

from bs4 import BeautifulSoup



url = "https://books.toscrape.com/"

res = requests.get(url)

soup = BeautifulSoup(res.text, 'html.parser')



libros = soup.select("article.product_pod")



# Creamos el archivo CSV

with open("libros.csv", "w", newline="", encoding="utf-8") as f:

      writer = csv.writer(f)

      writer.writerow(["Título", "Precio"])  # Encabezados



      for libro in libros[:5]:
```

```
        titulo = libro.h3.a['title']

        precio = libro.select_one(".price_color").text

        writer.writerow([titulo, precio])

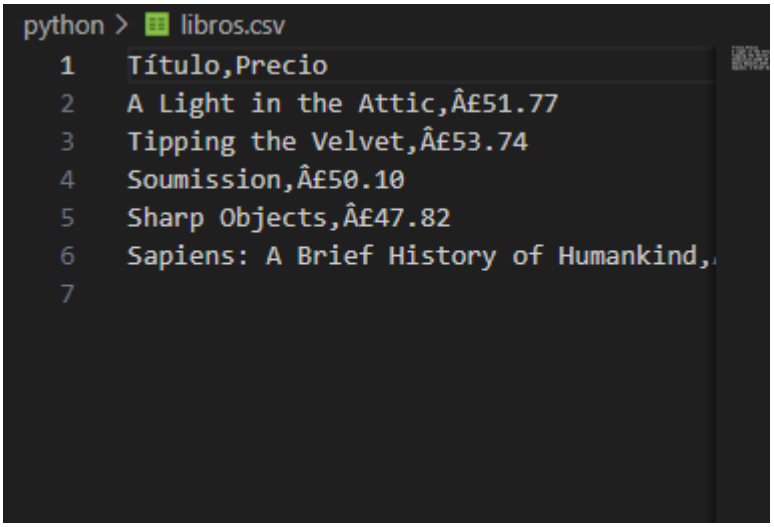


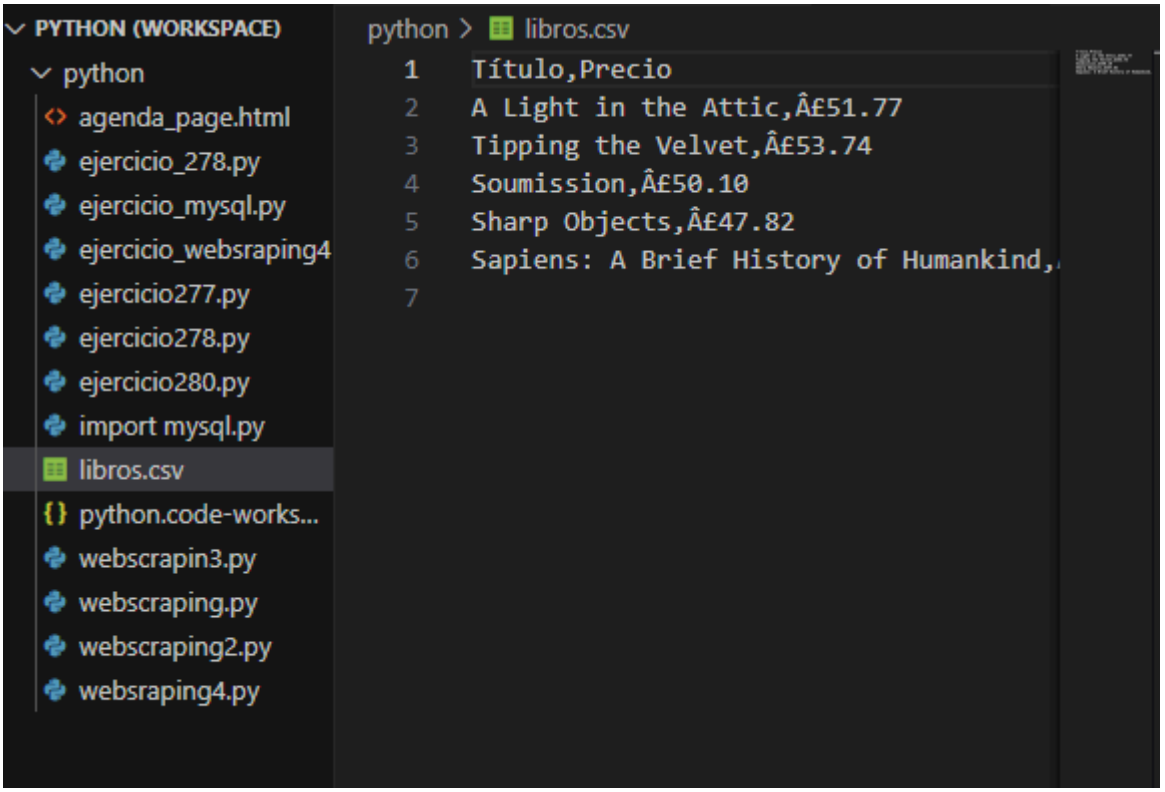
print("✅ Datos guardados en libros.csv")
```

python > ejercicio_websraping4 > ...

```
1   import csv
2   import requests
3   from bs4 import BeautifulSoup
4
5   url = "https://books.toscrape.com/"
6   res = requests.get(url)
7   soup = BeautifulSoup(res.text, 'html.parser')
8
9   libros = soup.select("article.product_pod")
10
11  # Creamos el archivo CSV
12  with open("libros.csv", "w", newline="", encoding="utf-8")
13      writer = csv.writer(f)
14      writer.writerow(["Título", "Precio"])  # Encabezados
15
16      for libro in libros[:5]:
17          # Asegúrate de usar 8 espacios o dos tabulaciones
18          titulo = libro.h3.a['title']
19          precio = libro.select_one(".price_color").text
20          writer.writerow([titulo, precio])
21
22  print("✅ Datos guardados en libros.csv")
```

```
such file or directory
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/Windo
wsApps/python3.13.exe "c:/Dlore python/python/ejercicio_websraping4"
✅ Datos guardados en libros.csv
PS C:\Dlore python\python>
```





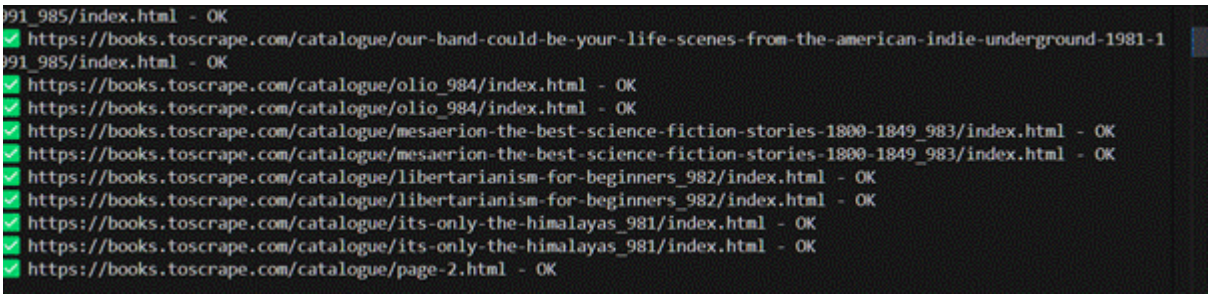
🧪 Ejercicio 5: Detección de enlaces rotos

Objetivo: Comprobar si los enlaces de una web funcionan.

Instrucciones:

1. Extrae todos los `<a href="...">`.

2. Usa `requests.head()` para comprobar si el enlace devuelve un código 200.

3. 

python > ejercicio_websrapin5.py > ...

```python
import requests
from bs4 import BeautifulSoup
from urllib.parse import urljoin # Para construir URLs abs

def verificar_enlaces(url_base):
    """Extrae todos los enlaces de una URL y verifica su c

    print(f"[*] Accediendo a la URL base: {url_base}")

    try:
        # 1. Obtener el HTML
        res_base = requests.get(url_base, timeout=10)
        res_base.raise_for_status() # Lanza una excepción

        soup = BeautifulSoup(res_base.text, 'html.parser')

        # 2. Extraer todos los elementos <a>
        enlaces_a = soup.find_all('a', href=True)

        if not enlaces_a:
            print("[!] No se encontraron etiquetas <a> cor
            return

        print(f"[*] Se encontraron {len(enlaces_a)} enlace
        print(" " * 40)
```

Extensions (Ctrl+Shift+X)

PROBLEMS OUTPUT TERMINAL ··· Python

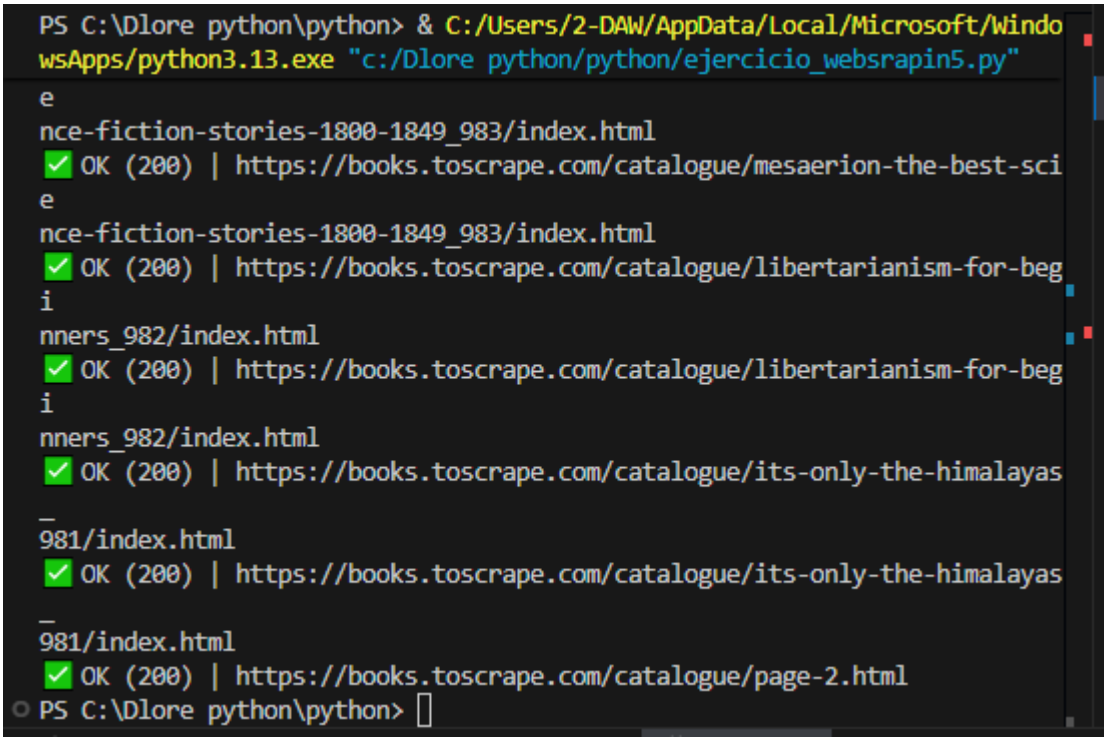
```
al\packages\pythonsoftwarefoundation.python.3.13_qbz5n2kfra8p0\localcache
\local-packages\python313\site-packages (from requests) (3.11)
Requirement already satisfied: urllib3<3,>=1.21.1 in c:\users\2-daw\appda
ta\local\packages\pythonsoftwarefoundation.python.3.13_qbz5n2kfra8p0\loca
lcache\local-packages\python313\site-packages (from requests) (2.5.0)
Requirement already satisfied: certifi>=2017.4.17 in c:\users\2-daw\appda
ta\local\packages\pythonsoftwarefoundation.python.3.13_qbz5n2kfra8p0\loca
lcache\local-packages\python313\site-packages (from requests) (2025.10.5)
Requirement already satisfied: soupsieve>1.2 in c:\users\2-daw\appdata\lo
cal\packages\pythonsoftwarefoundation.python.3.13_qbz5n2kfra8p0\localcach
e\local-packages\python313\site-packages (from beautifulsoup4) (2.8)
Requirement already satisfied: typing-extensions>=4.0.0 in c:\users\2-daw
\appdata\local\packages\pythonsoftwarefoundation.python.3.13_qbz5n2kfra8p
0\localcache\local-packages\python313\site-packages (from beautifulsoup4)
 (4.15.0)

[notice] A new release of pip is available: 25.2 -> 25.3
[notice] To update, run: C:\Users\2-DAW\AppData\Local\Microsoft\WindowsAp
ps\PythonSoftwareFoundation.Python.3.13_qbz5n2kfra8p0\python.exe -m pip i
nstall --upgrade pip
PS C:\Dlore python\python>
```

```
nstall --upgrade pip
PS C:\Dlore python\python> python verificador_enlaces.py
C:\Users\2-DAW\AppData\Local\Microsoft\WindowsApps\python.exe: can't open
 file 'C:\\Dlore python\\python\\verificador_enlaces.py': [Errno 2] No su
ch file or directory
```

```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/Windo
wsApps/python3.13.exe "c:/Dlore python/python/ejercicio_websrapin5.py"
[*] Accediendo a la URL base: https://books.toscrape.com/
[*] Se encontraron 94 enlaces en total.
----------------------------------------
✅ OK (200) | https://books.toscrape.com/index.html
✅ OK (200) | https://books.toscrape.com/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books_1/index
.
html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/travel_
2
/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/mystery
_
3/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/histori
c
al-fiction_4/index.html
```

```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/Windo
wsApps/python3.13.exe "c:/Dlore python/python/ejercicio_websrapin5.py"
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/default
_
15/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/science
-
fiction_16/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/sports-
a
nd-games_17/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/add-a-c
o
mment_18/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/fantasy
_
19/index.html
✅ OK (200) | https://books.toscrape.com/catalogue/category/books/new-adu
l
t_20/index.html
```



💡 Propuesta de proyecto final:

Crea un script que:

1. Busque información meteorológica (por ejemplo desde https://www.tiempo.com o similar).

2. Extraiga temperatura, estado del tiempo y ciudad.

3. Guarde los datos en un CSV para análisis posterior.

```
#!/usr/bin/env python3


# -*- coding: utf-8 -*-
```

```
import csv



import requests

from bs4 import BeautifulSoup



BASE = "https://www.tiempo.com/"

CITIES = {

    "Madrid": "madrid.htm",

    "Barcelona": "barcelona.htm",

    "Málaga": "malaga.htm",

}



rows = []



for ciudad, slug in CITIES.items():

    url = BASE + slug

    r = requests.get(url, headers={"User-Agent": "Mozilla/5.0"},
timeout=10)
```

```
    r.raise_for_status()



    soup = BeautifulSoup(r.text, "html.parser")



    # Selectores sencillos (ajusta si cambian en la web)

    temp_el = soup.select_one(".dato-temperatura")

    estado_el = soup.select_one(".descripcion")



    temperatura = temp_el.get_text(strip=True) if temp_el else ""

    estado = estado_el.get_text(strip=True) if estado_el else ""



    rows.append([ciudad, temperatura, estado])



# Guardar CSV

with open("meteo.csv", "w", newline="", encoding="utf-8") as f:

    writer = csv.writer(f)

    writer.writerow(["ciudad", "temperatura", "estado"])

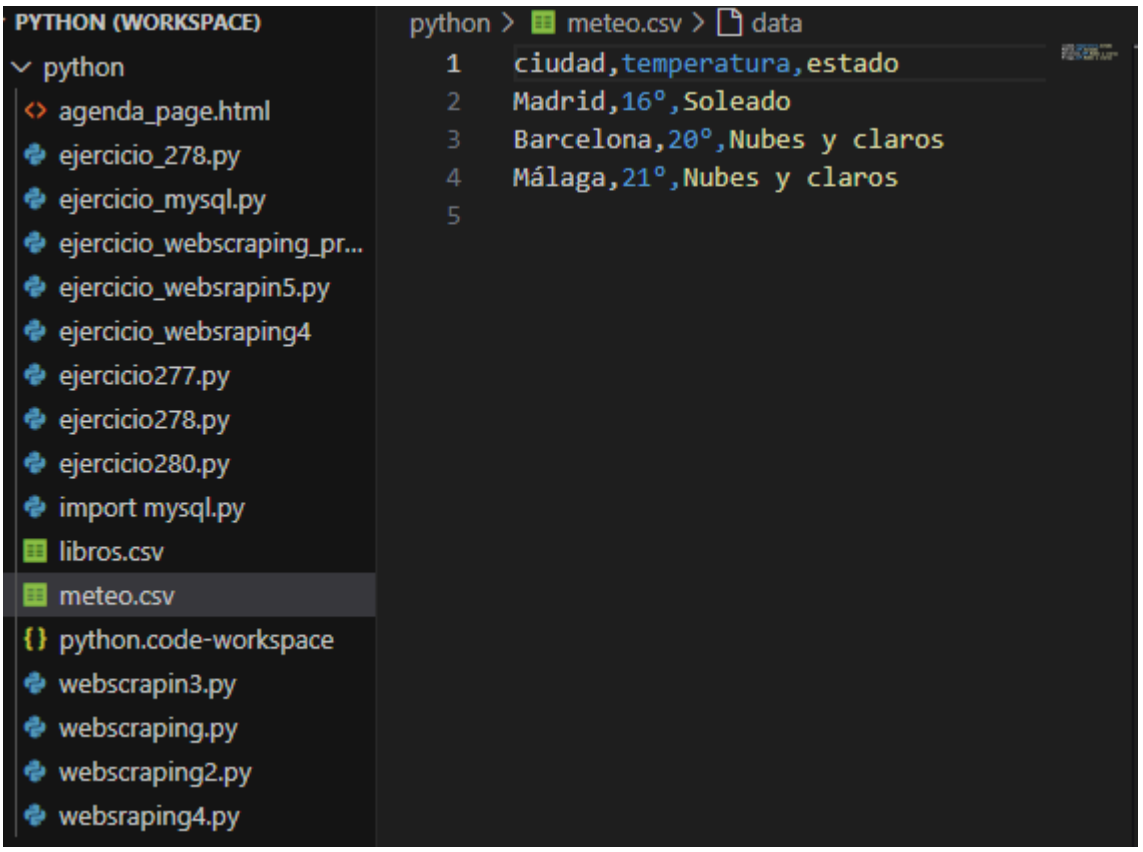
    writer.writerows(rows)
```

```
print("✅ Datos guardados en meteo.csv")
```

python > ejercicio_webscraping_proyecto.py > ...

```
4
5   import csv
6
7
8   import requests
9   from bs4 import BeautifulSoup
10
11
12  BASE = "https://www.tiempo.com/"
13  CITIES = {
14      "Madrid": "madrid.htm",
15      "Barcelona": "barcelona.htm",
16      "Málaga": "malaga.htm",
17  }
18
19
20  rows = []
21
22
23  for ciudad, slug in CITIES.items():
24      url = BASE + slug
25      r = requests.get(url, headers={"User-Agent": "Mozilla/
26      r.raise_for_status()
27
```

```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/WindowsApps/python3.13.exe "c:/Dlore python/python/ejercicio_webscraping_proyecto.py"
✅ Datos guardados en meteo.csv
PS C:\Dlore python\python>
```




```
PS C:\Dlore python\python> & C:/Users/2-DAW/AppData/Local/Microsoft/Windo
wsApps/python3.13.exe "c:/Dlore python/python/ejercicio_webscraping_proye
cto.py"
✅ Datos guardados en meteo.csv
PS C:\Dlore python\python>
```